Rapport de TP : détection de faux billets par apprentissage automatique

Nov 9, 2026 · @anass elhadbi

Un SVM à noyau RBF détecte les faux billets avec 99,7 % d'exactitude sur le jeu de test (1 erreur sur 337 billets), contre 54,7 % pour la simple référence « toujours authentique ».

1. Introduction

La question posée est la suivante : à partir de quatre statistiques calculées sur l'image numérisée d'un billet, peut-on prédire si ce billet est authentique ou faux ?

L'intérêt financier est direct. Un faux billet accepté par un guichet automatique, un commerçant ou une banque est une perte sèche. À l'inverse, rejeter un vrai billet fait perdre du temps et dégrade l'expérience du client. Les deux erreurs n'ont donc pas le même coût : laisser passer un faux billet coûte plus cher qu'un contrôle inutile. Pour cette raison, la classe « faux billet » est la classe positive, et le **rappel** (part des faux billets détectés) est suivi en priorité.

Le problème relève de l'**apprentissage supervisé**, plus précisément de la **classification binaire** : l'authenticité est connue pour chaque billet du jeu de données, et la cible ne prend que deux valeurs. Un algorithme de partitionnement, qui ne recevrait pas cette étiquette, relèverait de l'apprentissage non supervisé.

2. Données

Le jeu **Banknote Authentication** provient du dépôt UCI Machine Learning Repository (jeu n° 267). Il a été chargé directement depuis l'archive UCI dans Google Colab. Les données sont extraites d'images de billets authentiques et falsifiés, résumées par une transformée en ondelettes : chaque ligne est un billet décrit par quatre statistiques de son image.

Variable	Description	Minimum	Maximum
`variance`	Variance de l'image transformée	−7,04	6,82
`skewness`	Asymétrie de l'image transformée	−13,77	12,95
`kurtosis`	Aplatissement de l'image transformée	−5,29	17,93
`entropy`	Entropie de l'image	−8,55	2,45
`classe`	Cible : 0 = authentique, 1 = faux	0	1

Le jeu contient 1 372 billets, sans aucune valeur manquante, mais **24 lignes sont des doublons exacts**. Elles sont supprimées avant le découpage, ce qui laisse 1 348 billets (738 authentiques et 610 faux). Avant nettoyage, les classes sont modérément déséquilibrées : 762 billets authentiques (55,5 %) contre 610 faux (44,5 %). La convention 0 = authentique, 1 = faux est la convention usuelle de ce jeu.

3. Méthodologie

La démarche suit six étapes, avec une graine aléatoire fixée à 42 pour la reproductibilité.

1. **Nettoyage** : suppression des 24 doublons avant le découpage. Un même billet présent en double pourrait sinon se retrouver à la fois dans l'entraînement et dans le test, ce qui gonflerait le score (fuite de données).
2. **Découpage stratifié** : 75 % pour l'entraînement (1 011 billets) et 25 % pour le test (337 billets). Les proportions de faux billets sont conservées : 45,3 % dans l'entraînement et 45,1 % dans le test.
3. **Prétraitement** : standardisation des quatre variables (moyenne nulle, écart-type 1), apprise sur l'entraînement seul grâce à un `Pipeline`.
4. **Modèles comparés** : une référence qui prédit toujours la classe majoritaire, la régression logistique, un SVM à noyau RBF, un arbre de décision de profondeur 4 et une forêt aléatoire de 200 arbres.
5. **Sélection** : validation croisée stratifiée à 5 plis sur l'ensemble d'entraînement. Le jeu de test n'est utilisé qu'une seule fois, à la fin.
6. **Métriques** : exactitude, rappel et précision de la classe « faux », ROC-AUC et PR-AUC (aire sous la courbe précision-rappel). Le meilleur modèle est celui qui obtient le meilleur PR-AUC en validation croisée, l'exactitude départageant les égalités.

4. Exploration des données

Les deux classes sont d'effectifs comparables, mais pas égaux : la validation stratifiée et le suivi du rappel sont donc justifiés.

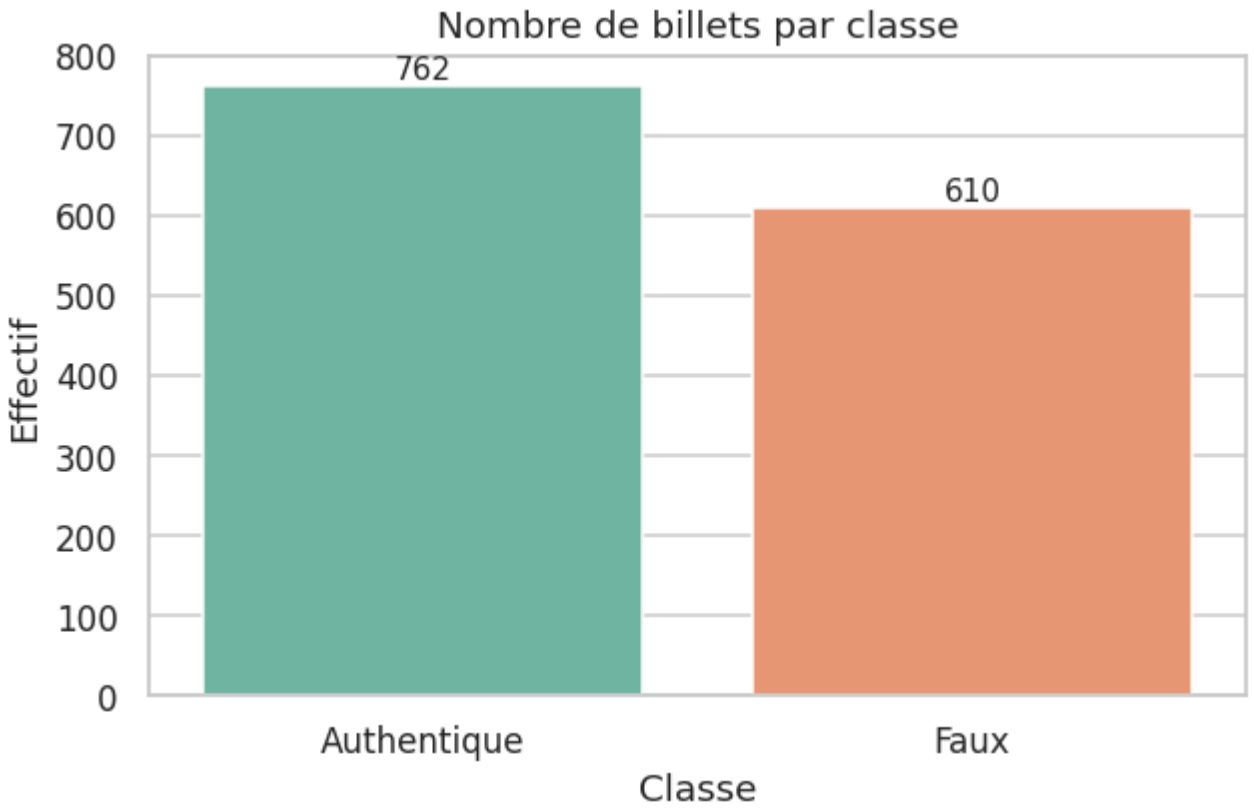


Figure 1 : nombre de billets par classe avant suppression des doublons.

La **variance** est la variable la plus discriminante : les faux billets sont centrés autour de −2, les billets authentiques autour de +3 ou +4, avec un recouvrement limité. L'**asymétrie** sépare aussi en partie les deux classes. L'**aplatissement** et surtout l'**entropie** se recouvrent presque complètement : seules, elles distinguent mal les billets.

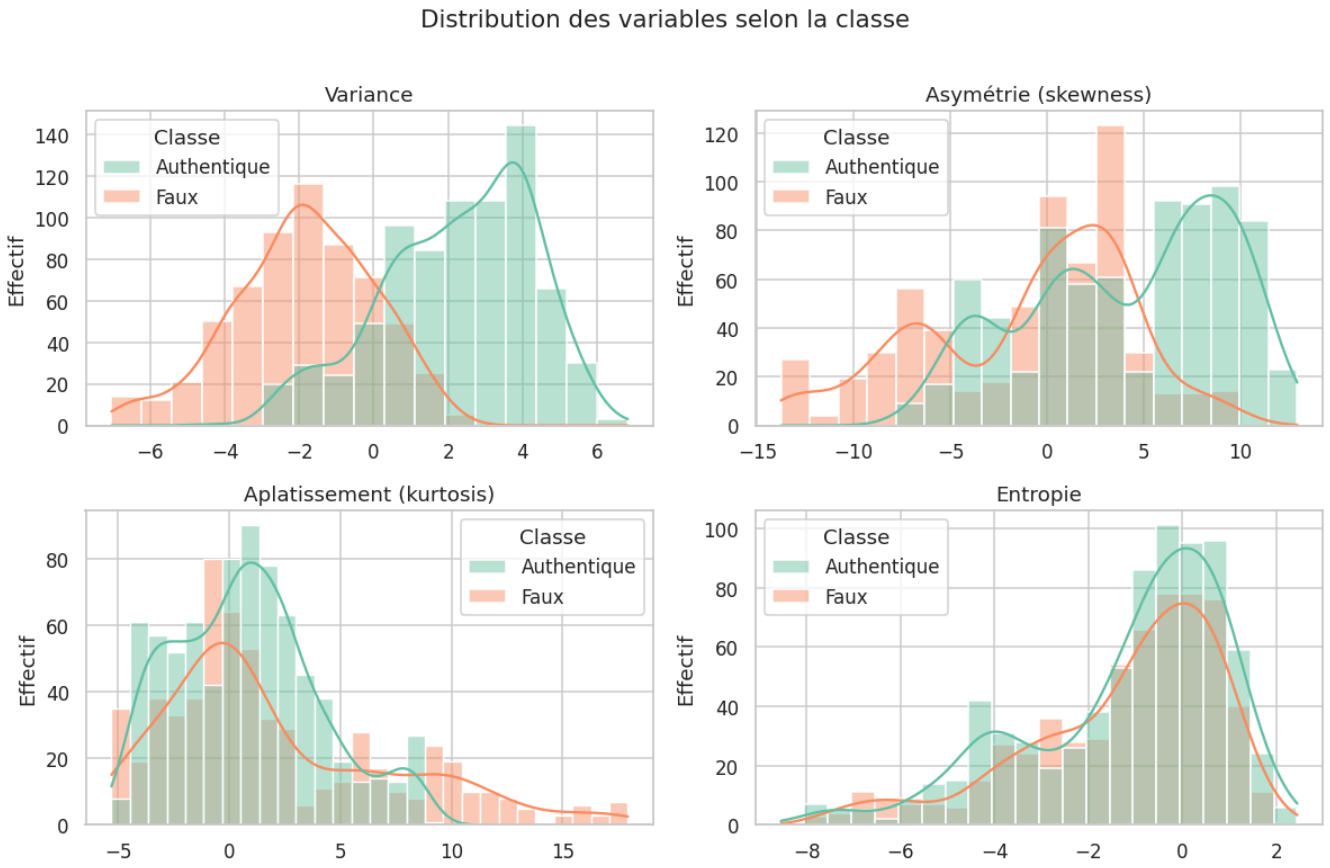


Figure 2 : distribution des quatre variables selon la classe.

La corrélation la plus forte lie l'asymétrie et l'aplatissement (−0,79) : elles portent en partie la même information. Ce n'est pas gênant pour un arbre ou une forêt, et la régression logistique de scikit-learn est régularisée par défaut. Dans le plan variance–asymétrie, la frontière entre les classes semble courbe, ce qui justifie d'essayer des modèles non linéaires.

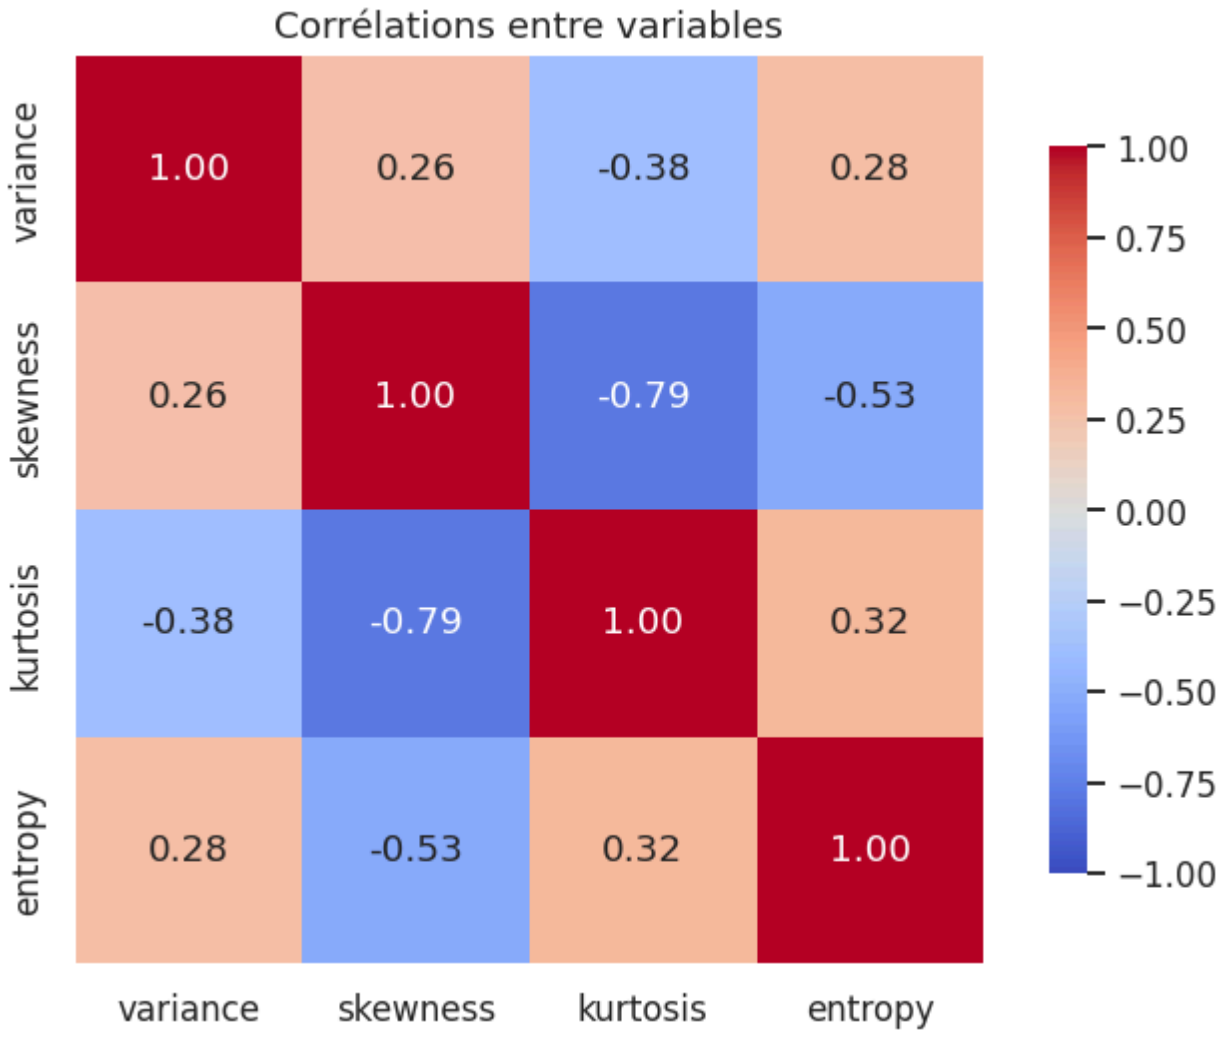


Figure 3 : matrice de corrélation des variables.

5. Comparaison des modèles

Le SVM obtient la meilleure exactitude en validation croisée (0,998), devant la régression logistique (0,994) et la forêt aléatoire (0,991). La référence, qui prédit toujours « authentique », atteint 0,547 d'exactitude mais détecte **0 faux billet** : l'exactitude seule est trompeuse.

Modèle	Exactitude	Écart-type	Rappel (faux)	Précision (faux)	ROC-AUC	PR-AUC
SVM (noyau RBF)	0,998	0,002	1,000	0,996	1,000	1,000
Régression logistique	0,994	0,002	0,998	0,989	1,000	1,000
Forêt aléatoire	0,991	0,011	0,998	0,983	1,000	1,000
Arbre de décision (profondeur 4)	0,967	0,007	0,980	0,950	0,981	0,963

Modèle	Exactitude	Écart-type	Rappel (faux)	Précision (faux)	ROC-AUC	PR-AUC
Référence (classe majoritaire)	0,547	0,002	0,000	0,000	0,500	0,453

Les trois premiers modèles ont des ROC-AUC et PR-AUC arrondis à 1,000. Leurs écarts d'exactitude représentent quelques billets sur 1 011 : le classement entre eux est fragile et ne prouve pas qu'un modèle soit réellement meilleur que les autres. La forêt est la moins stable d'un pli à l'autre (écart-type 0,011). L'arbre de profondeur 4 est un cran en dessous.

6. Évaluation finale sur le jeu de test

Le SVM, sélectionné automatiquement, est entraîné sur tout l'ensemble d'entraînement puis évalué une seule fois sur les 337 billets du test. Il atteint une exactitude de 0,997, avec un ROC-AUC et un PR-AUC arrondis à 1,000.

Classe	Précision	Rappel	Effectif
Authentique	1,00	0,99	185
Faux	0,99	1,00	152

La matrice de confusion montre **une seule erreur** : un billet authentique rejeté à tort (faux positif). Aucun faux billet n'est accepté (0 faux négatif) : le rappel de la classe « faux » est de 1,00, résultat souhaité vu l'asymétrie des coûts. Une erreur isolée ne suffit pas à conclure, d'où l'intérêt de la validation croisée.

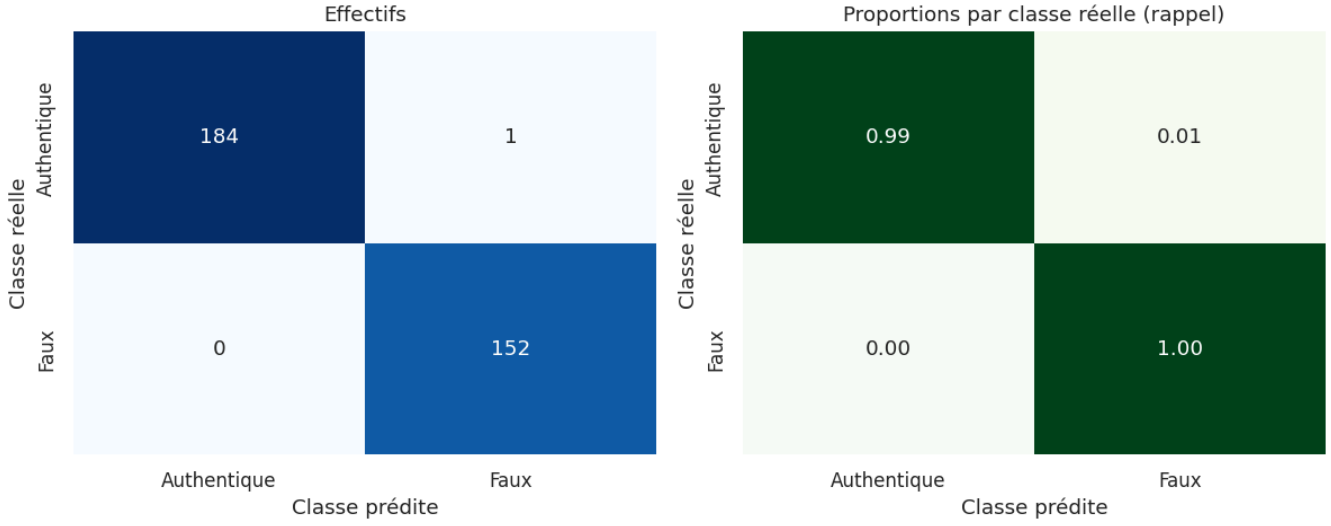


Figure 4 : matrice de confusion du SVM sur le jeu de test (effectifs et proportions par classe réelle).

Les courbes ROC et précision-rappel longent le coin supérieur gauche et le bord supérieur du graphique. L'unique erreur tient au seuil de décision par défaut : un seuil légèrement différent suffirait à l'éviter sur ce jeu de test.

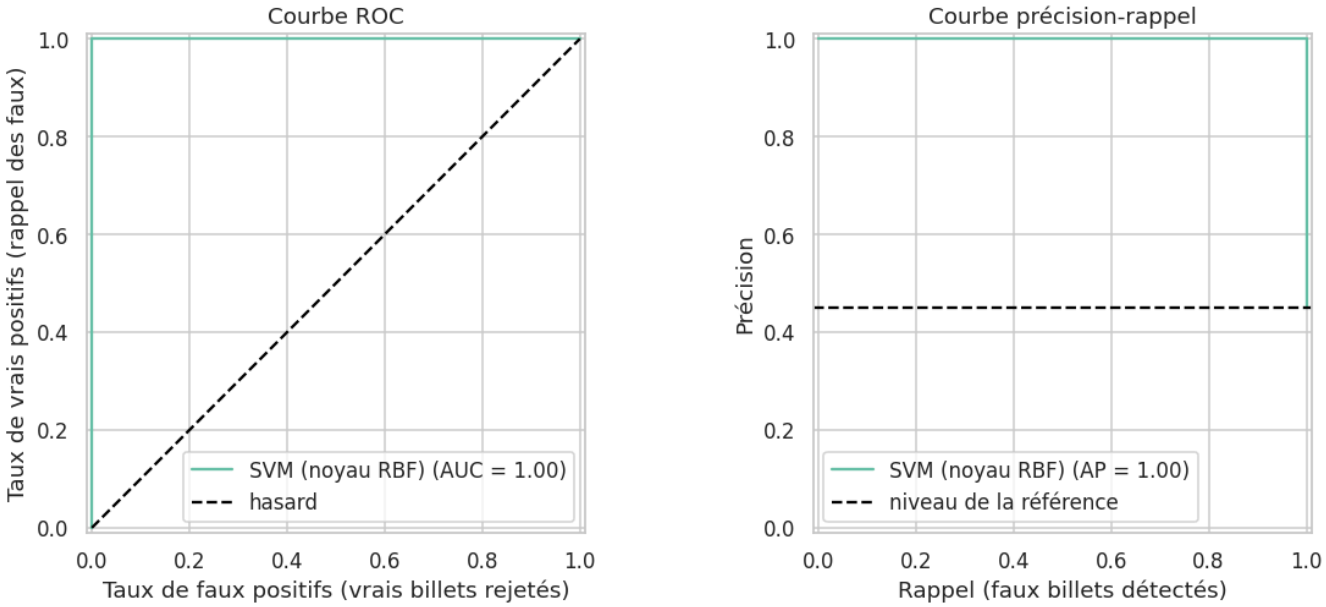


Figure 5 : courbes ROC et précision-rappel du SVM sur le jeu de test.

La courbe d'apprentissage montre que, dès 80 observations environ, les scores d'entraînement et de validation sont proches de 0,99, puis se confondent. Il n'y a ni sous-apprentissage ni surapprentissage notable, et ajouter des données n'améliorerait presque pas ce modèle.

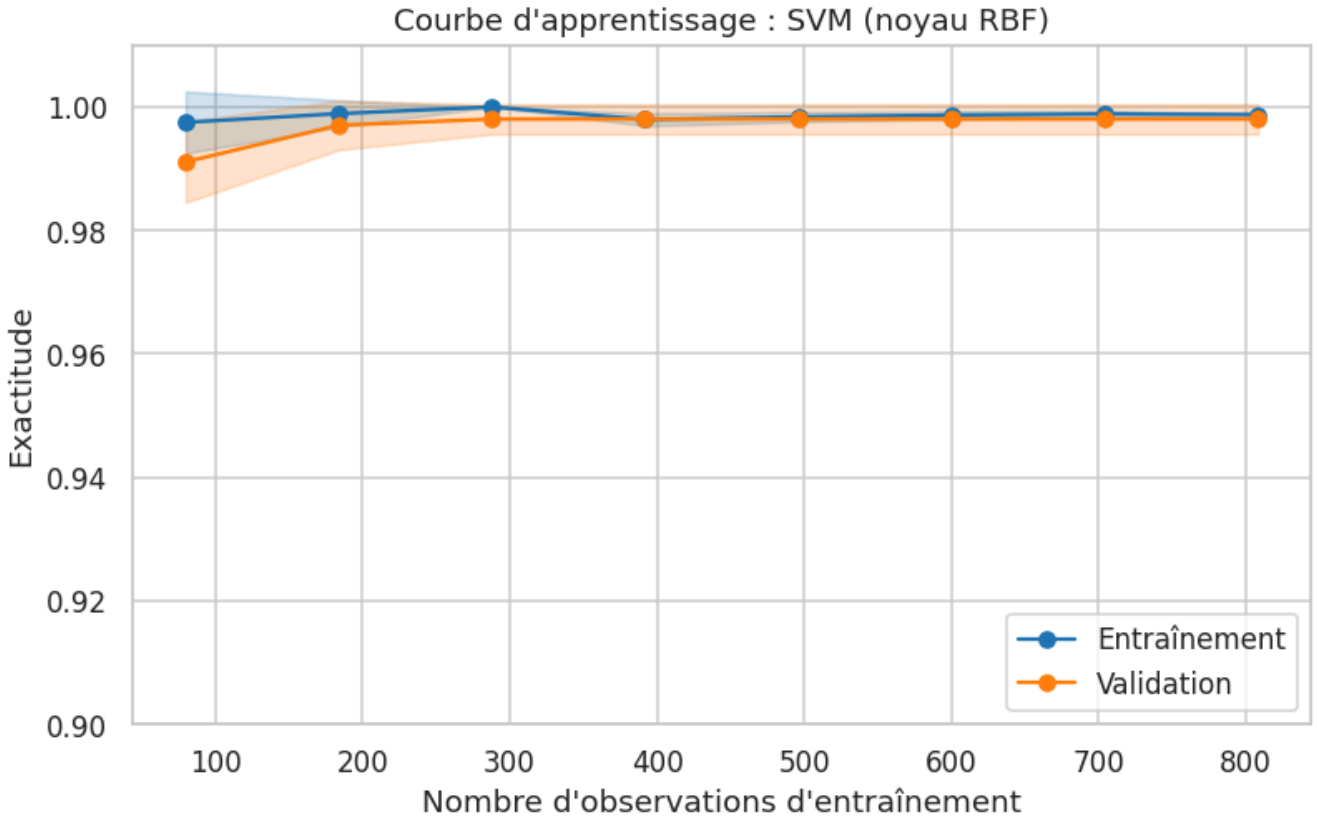


Figure 6 : courbe d'apprentissage du SVM (exactitude selon le nombre d'observations d'entraînement).

7. Interprétation du modèle

Selon la forêt aléatoire, la **variance** domine nettement (plus de la moitié de l'importance), suivie de l'asymétrie puis de l'aplatissement. L'entropie pèse très peu, ce qui est cohérent avec les histogrammes. Cette importance dépend du modèle et peut être biaisée quand des variables sont corrélées ; elle oriente l'analyse sans établir de causalité.

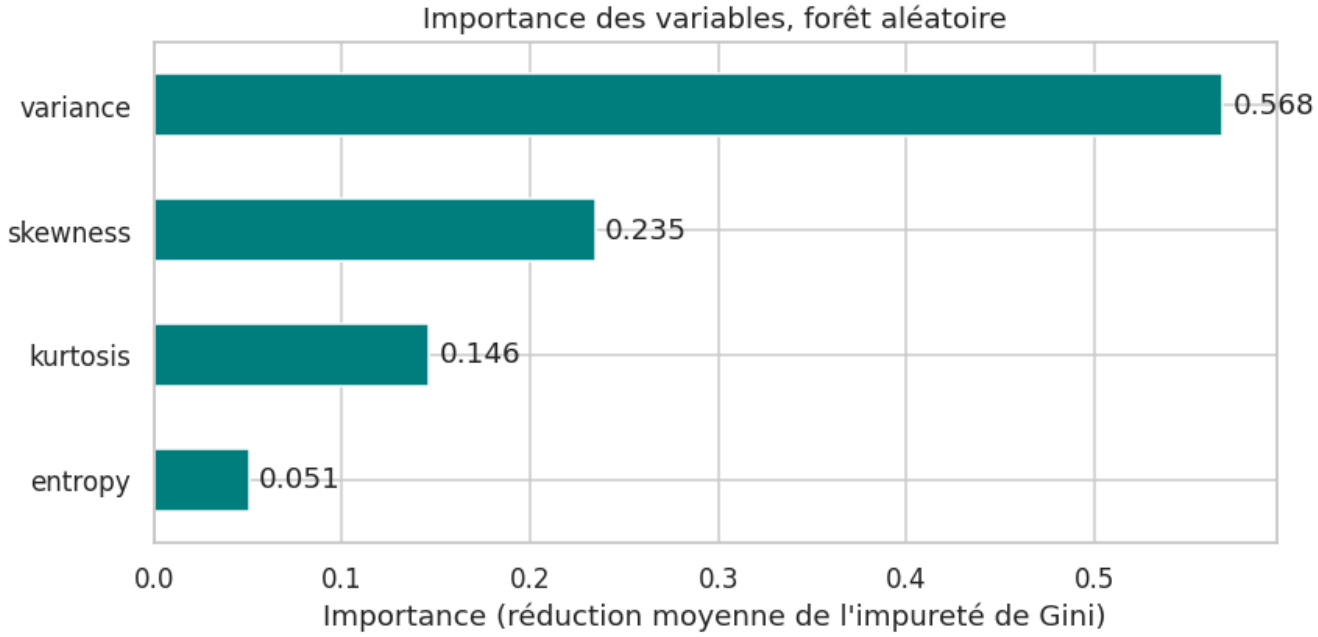


Figure 7 : importance des variables selon la forêt aléatoire.

Sur la figure des frontières de décision, construite avec deux variables seulement (variance et asymétrie), les faux billets sont à gauche et les authentiques à droite. Les points proches de la limite, vers une variance voisine de 0 et une asymétrie entre 0 et 5, sont les plus difficiles à classer. Le modèle complet, qui utilise aussi l'aplatissement et l'entropie, lève la plupart de ces ambiguïtés.

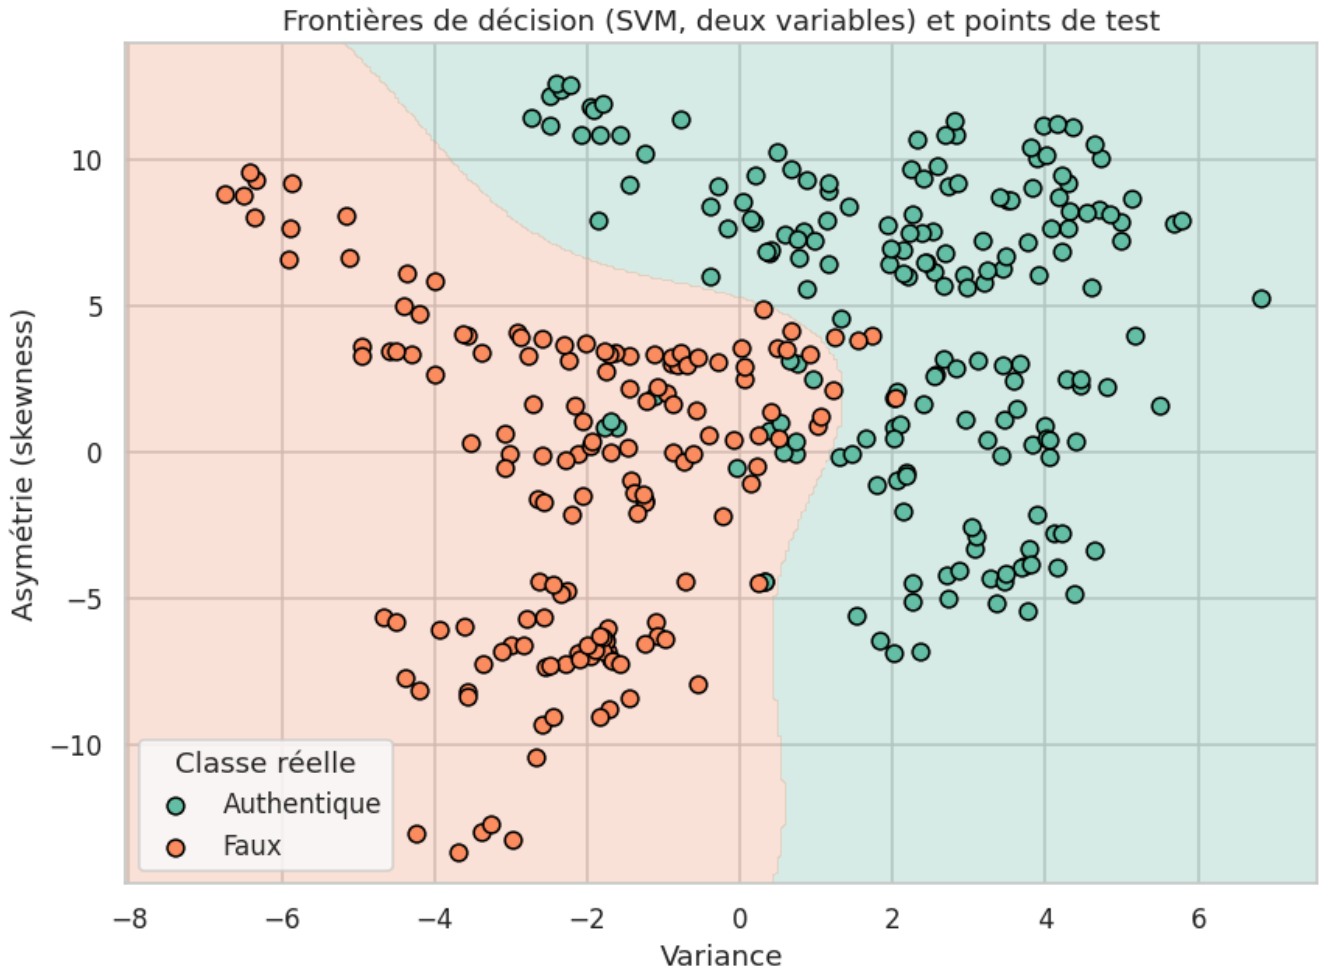


Figure 8 : frontières de décision du SVM avec deux variables, et points de test.

Appliqué à deux billets fictifs, le modèle classe le billet A comme authentique (score de décision −1,375) et le billet B comme faux (score de +1,040).

8. Limites du travail

- **Fuite de données** : les doublons, s'ils étaient conservés, fausseraient l'évaluation. Toutes les transformations sont apprises sur l'entraînement seul.
- **Déséquilibre** : les classes sont modérément déséquilibrées. Dans la réalité, les faux billets sont bien plus rares que dans ce jeu : tenir une précision élevée serait alors plus difficile.
- **Dérive temporelle** : les techniques de falsification évoluent. Un modèle entraîné sur les faux billets d'hier peut mal détecter ceux de demain.
- **Représentativité** : les 1 372 images proviennent d'un même protocole de numérisation. Un autre scanner, d'autres coupures ou d'autres types de faux pourraient donner des statistiques différentes.

- **Scores très élevés** : quand plusieurs modèles frôlent la perfection, leurs écarts sont dans le bruit d'échantillonnage. Un jeu de test d'environ 340 billets ne permet pas de les départager de façon fiable.
- **Coûts non modélisés** : le seuil de décision par défaut ne tient pas compte du fait qu'un faux billet accepté coûte plus cher qu'un vrai billet rejeté.

Ce travail est pédagogique : le modèle ne doit pas servir à une décision réelle de contrôle de billets.

9. Conclusion

Les quatre statistiques d'image permettent de séparer presque parfaitement les billets authentiques des faux. Le SVM à noyau RBF, sélectionné par validation croisée, détecte tous les faux billets du jeu de test et ne commet qu'une fausse alerte sur 337 billets, là où la référence n'en détecte aucun.

Trois enseignements ressortent. L'exactitude seule ne suffit pas : le rappel de la classe « faux » et la matrice de confusion montrent où le modèle se trompe et à quel coût. La suppression des doublons avant le découpage est indispensable pour éviter une évaluation faussée. Enfin, la quasi-égalité des trois meilleurs modèles invite à la prudence : pour aller plus loin, il faudrait tester le modèle sur d'autres sources de données et ajuster le seuil de décision à la différence de coût entre les deux erreurs.